

Mutation이 유전체 불안정성을 예측할 수 있는가

DNA mutation 정보만으로 Whole-Genome Doubling, Chromosomal Instability, Loss of Heterozygosity를 예측하고, 최소 mutation biomarker panel을 찾는다.

WGD

CIN

LOH

1,631 cell lines

20,132 mutation features

5 models compared

32 lineages

BACKGROUND

세 가지 유전체 불안정성 표현형

암세포는 정상 염색체 수·구조 유지에 실패하는 경우가 많다. 이 실패의 세 가지 서로 다른 얼굴을 각각 예측 대상으로 삼는다 — 하나의 "불안정성 점수"로 뭉치지 않는다.

WGD

65.2%

Whole Genome Doubling · 이진 라벨, 양성 다수 클래스

CIN

이봉형

Chromosomal Instability · 연속값, 중앙값 이진화

LOH

0 치우침

Loss of Heterozygosity · 연속값, 중앙값 이진화

DepMap Public 26Q1

hotspot(기능 획득 추정) 554개 + damaging(기능 손실 추정) 19,578개 mutation feature.

CNV·ploidy·expression·TMB는 정답 누출 위험으로 의도적으로 제외했다.

- **1,631** 세포주 — 3개 라벨 전부 관측된 것만
- **20,132** feature — hotspot 554 + damaging 19,578
- **32** lineage — 암종 그룹, generalization 검증용

Figure 2. WGD / CIN / LOH 분포와 mutation 빈도




Figure — WGD/CIN/LOH 분포. WGD는 이진, CIN은 이봉형, LOH는 0 근처로 치우침.

METHOD


누출 없는 검증 — Nested Cross-Validation

희귀 변이 제거, CIN/LOH 이진화 threshold, hyperparameter, feature selection, 분류
threshold — 전부 **각 training fold 안에서만** 결정한다. outer test 데이터는 어떤 단계에도
관여하지 않는다.

- **Outer 5-fold** — 최종 성능 평가
- **Inner 5-fold** — hyperparameter 튜닝, threshold 결정
- **5개 모델** — Logistic, Elastic Net, Random Forest, XGBoost, CatBoost


Random Forest가 세 표현형 모두에서 1위

Figure 3. 모델별 예측 성능 (random 5x5 nested CV, 오차막대는 fold 표준편차)



비선형 모델(RF/XGBoost/CatBoost, 평균 0.73-0.74)이 선형 모델(평균 0.69-0.71)을 일관되게 앞서지만 차이는 0.05 내외 — 변이 간 interaction이 있지만 크지는 않다는 뜻이다.

Figure 16. Random Forest confusion matrix — 5개 outer fold pooled (n=1,631)
(threshold 는 각 fold training 데이터의 out-of-fold 예측으로 결정, §13)



BEST MODEL DETAIL

Random Forest Confusion Matrix

5개 outer fold의 test 예측을 pooled — WGD는 다수 클래스(65.2%) 쪽으로 쏠린 오류 패턴,
LOH는 specificity(0.606)가 가장 낮다.

WGD ROC-AUC

0.765

CIN ROC-AUC

0.734

LOH ROC-AUC


0.730

최소 10개 mutation으로 93-99% 유지

전체 ~2,062개(필터 후) 중 10개로 줄여도 성능 대부분이 남는다. 다만 fold마다 정확히 어떤 유전자가 뽑히는지는 흔들린다 — 그래서 고정 10개 패널 대신 **합의 유전자**를 제시한다.

- **TP53** — 세 표현형 모두 평균 순위 1위, 순위 표준편차 0
- **ID3 · BRAF · CREBBP** — 세 표현형 공통 후보

Figure 5. 패널 크기별 예측 성능 (점선은 전체 feature 성능)



FOLLOW-UP EXPERIMENTS

세 가지 표현 방식을 더 시도했다

"유전자 정체성"이 아닌 다른 축으로 mutation을 재구성하면 어떻게 될까 — 결과는 정반대로 갈랐다.

표현 방식	아이디어	결과
Pathway 재집계	20,132개 유전자 → 11개 gene set	음성 · 6/6 하락
Mutation Signature	96-class 치환 context (COSMIC SBS)	양성 · 5/6 개선
유전자 + Signature 결합	두 축을 한 feature 공간에 결합	양성 · 6/6 개선

뭉뚱그리면 정보가 희석된다

MSigDB Hallmark + KEGG DNA repair, 11개 gene set으로 재집계 — 핵심 신호가 TP53 같은
소수 유전자에 집중돼 있어, pathway 평균으로 뭉치면 오히려 정보가 사라진다.

Figure 10. 유전자 단위 vs Pathway 단위 — sparsity 완화가 천장을 뚫었는가
(막대 위 숫자 = pathway - 유전자단위. 6개 조합 전부 음수: 천장을 못 뚫음)





Figure 12. 유전자 단위 vs Mutation Signature(96-class) — 5/6 조합에서 개선
(막대 위 숫자 = signature - 유전자단위. Figure 10(pathway, 전부 음성)과 대비)



FOLLOW-UP — SIGNATURE (양성)

"어떤 과정이었는가"는 다른 정보였다

COSMIC SBS 96-class 치환 비율 — 유전자 정체성이 아니라 변이 발생 과정(APOBEC, MMR 결손 등) 정보다. 96개라는 훨씬 적은 차원으로 유전자 ~2,062개 수준의 성능을 냈다.

결합하면 항상 더 낫다

유전자 + signature를 한 feature 공간에서 함께 선택 — 6개 조합 전부 단일 축보다 높다.

Random Forest + WGD(0.797)는 프로젝트 전체 최고 ROC-AUC다.

Figure 17. 유전자+Signature 결합 패널 — 성능은 항상 개선, 구성은 모델마다 다르다
(RF는 signature 쪽으로 쏠림 — RF impurity importance의 연속형 feature 편향 가능성, 본문 참고)





Figure 11. TCGA 독립 코호트 검증 (WGD, damaging-only)
 (b)는 (a)의 하락폭 -0.168 을 '일반화 실패'로 단정하면 안 되는 이유:
 TP53 missense 2,927건 중 대부분이 truncating-only 기준에서 누락됨



EXTERNAL VALIDATION

TCGA 실제 환자 종양으로 검증

DepMap 세포주가 아닌 실제 종양(TCGA)에서 WGD를 검증 — 내부 0.762 → 외부 0.594.

TP53 missense 근사 한계로 인한 **하한 추정치**에 가깝다.

최종 후보 Biomarker Panel — 8개 유전자

fold 반복선택 · 모델 간 합의 · 회귀 재검증 · TCGA 방향성 지지를 종합했다.

TP53

WGD·CIN·LOH 공통

세 표현형 전부 평균 순위 1위

ID3

WGD·CIN·LOH 공통

전사 억제 조절인자

BRAF

WGD·CIN·LOH 공통

MAPK 신호 kinase (hotspot)

CREBBP

WGD·CIN·LOH 공통

히스톤 아세틸화 공활성인자

TERT

WGD 특이

telomerase 역전사효소 (hotspot)

RB1

CIN 특이

G1/S checkpoint 억제자

PIK3CA

CIN 특이

PI3K 촉매 subunit (hotspot)

PITX1

LOH 특이

발생 전사인자

CONCLUSION

Mutation만으로 acceptable 수준까지, 확정 바이오마커는 아직 아니다

ROC-AUC 0.73-0.77 — DNA mutation만으로 유전체 불안정성 예측이 가능하다는 신호는 분명하지만, 유병률 대비 이득과 확률 보정은 제한적이고, lineage(암종) 일반화도 아직 규명되지 않았다. Pathway(음성)와 Signature(양성)가 정반대로 갈린 것은, "유전자 정체성"과 "변이 발생 과정"이 서로 다른 상보적 정보라는 것을 보여준다.

github.com/lleonwoo94/AI-bio-proj-team-1