


association_combined_kr.png

유전자-표현형 통계적 연관성 (Chi-square/Fisher 검정, FDR 보정)



-> 유전자 하나하나가 표현형이랑 통계적으로 관련 있는지를 검정(Fisher/chi-square) → 관련성의 방향과 크기를 정량화(OR, CI) → 수천 번 검정한 걸 보정(FDR) → 상위 30개를 보기 좋게 시각화한 결과

fig4_selection_stability_random_forest.png(깃허브)

Figure 4. 반복 feature selection 안정성 (Random Forest, outer 5-fold)




fig4는 RF 모델이 fold를 5번 다르게 나눠서 학습해도 매번 비슷한 유전자를 선택하는가(모델 기반 안정성)를 보여주는 그림으로 여기서 fold마다 안정적으로(빈도 1.0에 가깝게) 뽑히는 유전자가 있다는 건 "이 유전자들이 우연이 아니라 진짜 중요한 신호"라는 근거가 되고 RF라는 하나의 모델 안에서만 검증되었음을 보여주는 시각화 결과이니 association_combined_kr.png는 모델을 아예 쓰지 않고, 유전자 하나하나를 표현형이랑 직접 통계적으로 비교했을 때도 같은 유전자(TP53, ID3, RB1, CREBBP 등)가 유의하게 나온다면, RF가 학습한 게 아니라 데이터 자체에 실제로 그런 연관성이 있다는 근거

아래 표는 위의 시각화 결과를 상위 유전자 10개로 줄여서 표로 나타낸 것

(첫번째: 통계적 검정 / 두번째: WGD,CIN,LOH 각각 randomforest 모델)

association_tables_combined.png

WGD-CIN-LOH 연관 유전자 상세 수치 (Odds Ratio, 95% CI)

WGD 연관 유전자 상위 10개					CIN 연관 유전자 상위 10개					LoH 연관 유전자 상위 10개				
유전자	OR	95% CI	p-value	FDR q	유전자	OR	95% CI	p-value	FDR q	유전자	OR	95% CI	p-value	FDR q
TP53 (dmg)	4.20	(3.4-5.2)	< .001	< .001	TP53 (dmg)	3.20	(2.6-3.9)	< .001	< .001	TP53 (dmg)	3.49	(2.8-4.3)	< .001	< .001
TP53 (hs)	2.93	(2.4-3.6)	< .001	< .001	TP53 (hs)	2.29	(1.9-2.8)	< .001	< .001	TP53 (hs)	2.36	(1.9-2.9)	< .001	< .001
TERT (hs)	2.72	(1.9-3.8)	< .001	< .001	POSSB (dmg)	0.13	(0.1-0.3)	< .001	< .001	RPL22 (dmg)	0.03	(0.0-0.2)	< .001	< .001
ID3 (dmg)	0.03	(0.0-0.2)	< .001	< .001	TERT (hs)	1.96	(1.5-2.6)	< .001	< .001	ARID1A (dmg)	0.38	(0.3-0.6)	< .001	< .001
BRAF (hs)	3.15	(1.9-5.0)	< .001	< .001	RPL22 (dmg)	0.10	(0.0-0.4)	< .001	< .001	POSSB (dmg)	0.16	(0.1-0.4)	< .001	< .001
POSSB (dmg)	0.22	(0.1-0.4)	< .001	< .001	RB1 (dmg)	2.31	(1.6-3.4)	< .001	0.002	CTCF (dmg)	0.04	(0.0-0.3)	< .001	< .001
RPL22 (dmg)	0.18	(0.1-0.4)	< .001	< .001	RAD50 (dmg)	0.14	(0.1-0.4)	< .001	0.002	RB1 (dmg)	2.31	(1.6-3.4)	< .001	0.001
CREBBP (dmg)	0.37	(0.2-0.6)	< .001	0.001	ID3 (dmg)	0.00	(0.0-0.4)	< .001	0.002	RAD50 (dmg)	0.14	(0.1-0.4)	< .001	0.001
GNA13 (dmg)	0.13	(0.0-0.4)	< .001	0.001	CREBBP (dmg)	0.35	(0.2-0.6)	< .001	0.002	ID3 (dmg)	0.00	(0.0-0.4)	< .001	0.001
RAD50 (dmg)	0.24	(0.1-0.5)	< .001	0.003	MSH3 (dmg)	0.22	(0.1-0.5)	< .001	0.002	PITPR3 (dmg)	0.00	(0.0-0.4)	< .001	0.001

-> 앞서 통계적 검정(association_combined_kr.png)결과 중 상위 10개 유전자 표로 정리한 이미지

model_selection_tables_combined.png

WGD-CIN-LOH 모델 기반(Random Forest) 상위 유전자 상세 수치

WGD — RF importance 상위 10개					CIN — RF importance 상위 10개					LoHFracton — RF importance 상위 10개				
유전자	RF importance	선택빈도	평균 순위	순위 표준편차	유전자	RF importance	선택빈도	평균 순위	순위 표준편차	유전자	RF importance	선택빈도	평균 순위	순위 표준편차
TP53 (dmg)	0.153	1.0	1.0	0.0	TP53 (dmg)	0.141	1.0	1.0	0.0	TP53 (dmg)	0.144	1.0	1.0	0.0
TP53 (hs)	0.094	1.0	2.0	0.0	TP53 (hs)	0.077	1.0	2.0	0.0	TP53 (hs)	0.075	1.0	2.0	0.0
TERT (hs)	0.032	1.0	3.4	0.5	TERT (hs)	0.019	1.0	3.8	0.8	RB1 (dmg)	0.017	1.0	3.8	1.3
BRAF (hs)	0.028	1.0	3.6	0.5	RB1 (dmg)	0.018	1.0	4.4	1.7	ID3 (dmg)	0.015	1.0	5.2	2.3
ID3 (dmg)	0.016	1.0	6.0	1.4	ID3 (dmg)	0.016	1.0	5.0	1.0	KRAS (hs)	0.013	1.0	6.0	1.4
TTN (dmg)	0.013	1.0	8.6	3.4	BRAF (hs)	0.016	1.0	5.2	1.5	NF2 (dmg)	0.012	1.0	7.2	2.9
KRAS (hs)	0.012	1.0	9.2	4.9	PKCACA (hs)	0.010	1.0	11.4	5.9	SMAD4 (dmg)	0.011	1.0	11.2	6.5
LRP1B (dmg)	0.011	1.0	8.2	1.3	CREBBP (dmg)	0.009	1.0	15.0	7.1	MUC19 (dmg)	0.010	1.0	16.0	12.6
RB1 (dmg)	0.010	1.0	11.8	6.1	KRAS (hs)	0.009	1.0	14.4	8.3	PTX1 (dmg)	0.009	1.0	10.0	2.5
CREBBP (dmg)	0.009	1.0	10.0	4.0	ASXL1 (dmg)	0.008	0.8	21.8	21.9	ARID1A (dmg)	0.009	1.0	10.0	3.1

-> Randomforest 모델 (깃허브 results/tables 경로의 day11_selection_random_forest_WGD.csv, day11_selection_random_forest_CIN.csv, day11_selection_random_forest_LOH.csv)결과 중 상위 10개 유전자 표로 정리한 이미지

model_vs_association_summary.csv


target,겹치는 개수,모델만,통계검정만,겹치는 유전자
WGD,6,4,4,"BRAF (673)_hotspot, CREBBP (1387)_damaging, ID3 (3399)_damaging, TERT (7015)_hotspot, TP53 (7157)_damaging, TP53 (7157)_hotspot"
CIN,6,4,4,"CREBBP (1387)_damaging, ID3 (3399)_damaging, RB1 (5925)_damaging, TERT (7015)_hotspot, TP53 (7157)_damaging, TP53 (7157)_hotspot"
LOH,5,5,5,"ARID1A (8289)_damaging, ID3 (3399)_damaging, RB1 (5925)_damaging, TP53 (7157)_damaging, TP53 (7157)_hotspot"

->모델이 뽑은 상위 10개 유전자와, 모델 없이 순수 통계 검정(chi-square/Fisher)만으로 뽑은 상위 10개 유전자를 비교했더니, WGD·CIN은 10개 중 6개, LOH는 5개가 겹침

우연히 이 정도로 겹칠 확률은 극히 낮다(필터 통과 유전자가 1,500개 정도인데, 무작위라면 평균 0.07개만 겹쳐야 함 즉 이건 모델이 우연히 찾은 패턴이 아니라 데이터에 실재하는 신호라는 뜻이다.

세 표현형 전부에서 겹친 유전자는 TP53(damaging/hotspot)과 ID3 뿐이다 — 이 둘은 어떤 방법으로 봐도, 어떤 표현형을 봐도 흔들리지 않는 가장 확실한 신호다.

umap_status_combined.png




mutation feature 중 코호트 전체에서 가장 흔하게 관측된 80개 mutation만 골라서 흔한 이진 데이터에 맞는 Jaccard 거리를 써서, 2차원으로 압축한 지도를 한 번 그리고, 그 위에 WGD/CIN/LOH 색만 바꿔가며 칠한 것
색이 섞여있고 분리가 제대로 되어 있지 않는 것을 확인 가능
즉 mutation 패턴만 보고는 WGD,CIN,LOH인지 아닌지 구분이 쉽게 안 된다는 뜻

->ROC-AUC가 0.73~0.77로 중간 수준의 이유를 시각적으로 뒷받침(발표 자료에 사용안해도 될 것 같기도 합니다!)


selection_dendrogram_combined.png

Fold별 feature selection 안정성 (Random Forest, 10-gene 패널)



->RF 모델을 outer 5-fold로 나눠서 학습할 때마다, 각 fold에서 top-10 패널에 어떤 유전자가 뽑혔는지 기록한 게 원본 데이터(day12_panel_picks_random_forest.csv).
 이것 "유전자 × fold" 행렬(그 유전자가 그 fold에서 뽑혔으면 1, 안 뽑혔으면 0)로 만들고,
 유전자끼리 "5개 fold에서 뽑힌/안 뽑힌 패턴"이 얼마나 비슷한지를 Jaccard 거리로
 계산해서,
 비슷한 유전자끼리 가까이 묶이도록 계층 군집화(dendrogram)로 그린 것
 (fig4랑 내용이 겹쳐서 발표자료에서는 빼도 괜찮을 것 같습니다!!)

cca_comparison_kr.png



->같은 mutation 압축 데이터(mutation_scaled)에, 왼쪽은 labels(cin/loh를 중앙값으로 이진화한 것), 오른쪽은 y(이진화 안 한 원본 연속값)를 각각 넣어서 CCA를 두 번 실행
 CCA는 "mutation 쪽 20차원"과 "표현형 쪽 3차원"에서 서로 가장 잘 대응하는 선형결합(1개 성분, n_components=1)을 찾고, 그 결과로 나온 두 점수(U, V) 사이의 상관계수 r을 계산
 왼쪽은 이진화된 라벨을 쓴 결과라 Y값이 2³=8가지 조합밖에 안 나와서 가로 줄무늬가 생기고, 오른쪽은 연속값을 그대로 써서 자연스러운 산점도
 ->mutation 패턴만으로 세 표현형이 공유하는 하나의 '유전체 불안정성 축'을 어느 정도는 재구성할 수 있지만, 완벽하게는 안 된다는 것.
 r이 0.9 이상으로 나왔다면 "셋을 하나로 합쳐서 봐도 무방하다"가 됐겠지만, 0.4~0.5 정도라 "일부는 공유하지만 각자 고유한 부분도 상당히 크다"는 결론
 multi-task ANN이 세 표현형을 한 모델로 예측했을 때 오히려 성능이 떨어졌던 것도, CCA의 r이 "완전한 하나"가 아니라 "부분적 공유"라는 걸 확인
 즉 이 CCA 그림 하나가 표현형 간 관계는 실재하지만 제한적이다라는 의미
 (프로젝트 결론인 wgd, cin, loh를 하나로 예측하는 것은 제한적이다를 데이터로 확인해본 결과라서 이것도 발표자료에서는 빼도 될 것 같습니다!!)