

DepMap DNA 변이 기반 유전체 불안정성 예측 및 최소 Mutation Biomarker Panel 발굴

AI bio team project 1조

이건우 원주영
정현희 박수현
김태현 배한얼

Background

암세포의 유전체 불안정성과 관련된 대표적인 세 가지 유전체 변화 특징

- WGD (Whole Genome Doubling)

전체 유전체가 한 번 더 복제된 상태

- CIN (Chromosomal Instability)

염색체 수 & 구조 계속 불안정하게 변하는 상태

- LOH (Loss of Heterozygosity)

서로 다른 두 유전정보 중 하나가 소실된 상태

핵심 질문

- Q1. Mutation만으로 WGD·CIN·LOH를 예측할 수 있는가?
- Q2. 어떤 유전자 변이가 반복적으로 선택되는가?
- Q3. 일부 핵심 mutation만으로 전체 모델 성능의 상당 부분을 유지할 수 있는가?
- Q4. 각각의 암종에서도 성능이 유지되는가?

Figure 1. 연구 전체 흐름




Figure 2. WGD/CIN/LOH 분포

10개보다 적은 세포주에서만 나타나는 너무 희귀한 mutation을 제외 후 모델 학습에 사용

1,631

암세포주

20,132

Mutation features

Hotspot mutation (554)

Damaging mutation (19,578)








Figure 3. 모델 예측 성능 비교
Logistic / Elastic Net / RF / XGBoost / ANN의 ROC-AUC 및 PR-AUC



Q1. Mutation만으로 WGD·CIN·LOH를 예측할 수 있는가?


가능. Random Forest 기준 ROC-AUC는 WGD 0.765, CIN 0.734, LOH 0.730
여러 모델 중 Random Forest가 가장 높은 예측 성능을 보임

Figure 4. Biomarker selection stability


유전자별 fold 선택 빈도

Random Forest, outer 5-fold


WGD 상위 30개



CIN 상위 30개



LOH 상위 30개




Q2. 어떤 유전자 변이가 반복적으로 선택되는가?

- 세 표현형 공통: TP53, ID3, BRAF, RB1, CREBBP
- WGD 특이: GNA13, KMT2D, CCND3, MSH3, NF1
- CIN 특이: TYRO3, NFE2L2, SLFN11, ASXL1, SLK
- LOH 특이: ARID1A, TET2, SMARCA4, PTEN, CTCF

TP53 변이가 여러 fold에서 반복적으로 높은 중요도를 보였으며 ID3, BRAF, CREBBP 등도 주요 예측 변수로 확인됨.

Figure 5. Panel size-performance curve

panel 크기 별 예측 성능 평가




Q3. 일부 핵심 mutation만으로 전체 모델 성능의 상당 부분을 유지할 수 있는가?

지표	표현형	10개 feature	전체 feature	유지율
ROC-AUC	WGD	0.729	0.765	95.3%
	CIN	0.682	0.734	92.9%
	LOH	0.687	0.730	94.1%
PR-AUC	WGD	0.800	0.841	95.1%
	CIN	0.635	0.706	89.9%
	LOH	0.628	0.696	90.2%

10개 mutation feature만 사용해도 전체 모델 대비
ROC-AUC의 약 93~95%
PR-AUC의 약 90~95% 유지

Figure 6. Lineage 기반 일반화 검증
Random CV에서 얻은 성능이 다른 암종에도 유지되는지 두 단계로 검증



Q4. 각각의 암종에서도 성능이 유지되는가?

일부 유지됐지만 모든 암종에서 동일하지는 않았음.
암종을 분리하면 평균 ROC-AUC가 약 0.05~0.07 감소하고, 암종별 편차가 나타나 추가 검증이 필요

최종 결론

암세포의 유전자 변이 정보만으로 WGD, CIN, LOH 상태를 무작위보다 높은 수준으로 구분할 수 있었고, TP53을 포함한 일부 유전자 변이가 반복적으로 중요한 특징으로 확인되었다.

약 10개의 변이만 사용해도 전체 모델과 비슷한 수준의 성능을 유지할 수 있어, 소수의 변이로 예측 정보를 줄일 가능성을 확인했다.

다만 암종을 분리한 검증에서 성능이 낮아지고 암종별 편차가 크게 나타났기 때문에, 모든 암종에 공통으로 적용되는 고정 바이오마커 패널로 해석하기는 어렵다. 각 암마다 데이터가 충분하면 성능이 올라갈 가능성이 있다고 생각한다.

따라서 해당 mutation panel은 향후 독립 코호트와 암종별 검증이 필요하다.

이번 프로젝트는 **유전자 변이만으로 유전체 불안정성을 예측할 수 있는 가능성을 확인하고, 추가 검증이 필요한 바이오마커 후보를 제시했다는 데 의미가 있다.**

감사합니다 :)